

从 VLA 到 WAM：具身智能的未来

摘要

视觉-语言-动作（VLA）模型通过统一多模态感知与动作生成，显著推动了具身智能的发展，但其普遍依赖二维输入和感知到动作的直接映射，难以显式建模三维物理世界的动态演化，在长程任务中常因缺乏预测能力而性能受限[1][2][7]。为突破这一瓶颈，世界动作模型（WAM）范式应运而生，它通过生成式框架对未来场景进行显式建模，将视觉预测与动作规划深度融合[1][5][8]。代表性工作中，3D-VLA构建了衔接三维感知、推理与行动的生成世界模型[1]；Fast-WAM证明视频协同训练本身即可提升世界表征，而非必需测试时迭代生成未来帧，从而在保持竞争力的同时将推理速度提升4倍以上[5]；OA-WAM则引入物体可寻址的槽状态空间，显著增强了场景扰动下的操作鲁棒性[8]。与此同时，为满足实时部署需求，高效VLA设计成为关键方向，包括基于混合专家的动态层跳过[4]、轻量化适配器[9][32]及模型-标记联合调度[38]等方法，在LIBERO、CALVIN等基准和真实机器人任务中实现了成功率与推理效率的双重提升[4][34][36]。上述进展表明，从VLA到WAM的演进正驱动具身智能由被动模仿转向预测性世界建模，未来研究需进一步整合高效训练、多模态感知融合与跨具身自适应能力，以实现通用、鲁棒的物理世界交互[6][18][26]。

关键词：VLA; WAM; embodied intelligence; vision-language-action model; world-action model; robot learning; sim-to-real transfer; multimodal perception; action planning; foundation model; interactive environment; embodied agent; simulation

目录

- 1 引言
- 2 相关工作与文献综述
 - 2.1 VLA模型的基础范式与演进
 - 2.2 效率与时效性的博弈：VLA的轻量化与加速
 - 2.3 长程任务与感知深化：推理、记忆与世界模型
 - 2.4 世界动作模型（WAM）的兴起与核心价值
- 3 从 VLA 到 WAM 的范式演进
 - 3.1 范式分野：端到端映射与世界模型预测
 - 3.2 VLA 的内在演进：感知增强与推理深化
 - 3.3 效率约束下的范式选择
 - 3.4 研究缺口与未来路径
- 4 世界-动作模型（WAM）的概念框架
 - 4.1 从端到端映射到生成式世界模型：WAM 的概念跃迁
 - 4.2 想象-执行范式的反思与 Fast-WAM 的实证分歧
 - 4.3 面向对象的可寻址表征：OA-WAM 的架构深化
 - 4.4 感知模态的拓展与未来方向
- 5 关键技术与实现路径
 - 5.1 世界模型与生成式架构的融合
 - 5.1.1 从VLA到WAM的范式演进
 - 5.1.2 3D生成世界模型
 - 5.2 高效模型设计与部署加速
 - 5.2.1 动态计算与模型稀疏化
 - 5.2.2 推理系统协同优化
 - 5.3 推理增强与长程规划
 - 5.3.1 显式思维链与层级推理
 - 5.3.2 记忆增强与多模态融合
 - 5.4 多模态感知与几何先验
 - 5.4.1 跨模态感知扩展
 - 5.4.2 几何感知与空间推理
- 6 VLA 与 WAM 的对比分析
 - 6.1 范式分野：端到端映射与生成式世界模型
 - 6.2 推理效率与未来想象的必要性考辨
 - 6.3 表征粒度与鲁棒性：槽位寻址与隐式解码
 - 6.4 融合趋势：迈向世界模型先验的策略学习
- 7 具身智能的未来影响
 - 7.1 VLA向3D世界模型的演化

7.2 从VLA到WAM：推理与预测的范式转移

7.3 长时域推理与多模态感知的突破

8 局限性与开放问题

8.1 计算效率与实时部署瓶颈

8.2 三维环境理解与空间推理局限

8.3 长程任务与时间推理鸿沟

8.4 感知鲁棒性与模态完整性

8.5 世界模型的核心收益与悬置假设

9 结论

9.1 VLA 模型的现有成就与核心瓶颈

9.2 世界行动模型（WAM）的范式升级

9.3 关键挑战与研究路径

9.4 未来方向

10 参考文献

1 引言

近年来，视觉-语言-动作（vision-language-action, VLA）模型通过将视觉、语言与动作统一到同一个端到端框架，使机器人能够根据自然语言指令和视觉输入直接生成操控动作，在具身智能领域取得了令人瞩目的进展[2, 10, 11]。然而，主流VLA模型仍主要依赖从当前感知到动作的直接映射，缺乏对物理世界动态演变的显式建模，这使其在面对长序列任务时容易出现误差累积与规划失效[1, 7]。为突破这一瓶颈，部分研究者开始转向世界动作模型（world action model, WAM），其核心思想是让模型同时预测未来场景状态与动作序列，从而赋予智能体一种“想象”未来并据此规划的能力[5, 8]。例如，3D-VLA通过生成式世界模型预测目标点云与图像，将动作生成建立在对未来三维场景的可视化推演之上[1]；OA-WAM则通过将每一帧分解为可寻址的对象槽状态，在场景扰动下实现了更鲁棒的操控[8]。该类模型曾普遍遵循“想象一再执行”的范式，但近期Fast-WAM的研究表明，WAM的性能增益主要源自训练阶段的视频建模对世界表征的改进，而非测试时显式的未来视频生成，这从根本上挑战了既有范式并大幅降低了推理延迟[5]。与此同时，VLA模型在高效架构设计、多模态感知融合以及长程推理等方面也取得了一系列并行进展[6, 19, 32]。本文系统梳理从VLA到WAM的范式演进，分析两者在模型构建、推理机制与训练策略上的内在关联与分野，并在此基础上探讨具身智能的未来发展方向。

2 相关工作与文献综述

2.1 VLA模型的基础范式与演进

视觉-语言-动作（VLA）模型已迅速成为具身智能领域的主导框架，其核心思路是将视觉感知、语言理解与动作生成统一于单一基础模型中，实现端到端的指令跟随操控[2,10,11,18]。早期VLA模型大多建立在视觉-语言大模型（VLM）之上，通过在海量机器人数据上预训练或微调，直接建立从感知表征到低层动作的映射[11]。然而，这种直接映射范式隐含地假定世界是静态的，忽视了物理交互中“动作如何导致状态变化”的丰富动态[1]。为克服这一局限，3D-VLA率先将生成式世界模型引入VLA，通过预测目标图像与点云来注入对未来场景的想象，从而增强规划与推理能力[1]。该尝试标志着从纯反应式VLA向具备内部世界模拟能力的具身智能体过渡的开端。

2.2 效率与时效性的博弈：VLA的轻量化与加速

VLA的基础模型通常参数量庞大，导致推理延迟高、计算开销大，难以满足真实机器人控制的实时性要求[6,30]。为此，研究者从模型架构、数据使用和推理优化三个维度展开轻量化工作。MoLe-VLA借鉴神经科学中的浅层脑假说，将LLM每一层视为一个专家，通过时空感知路由器动态激活部分层，在十项仿真任务中以36.8%的推理加速和9.7%的平均成功率提升超越OpenVLA[4]。VLA-Adapter则彻底绕开大规模机器人预训练，仅使用0.5B参数的主干配合桥接注意力模块，在单张消费级GPU上训练数小时即可达到领先性能[9,32]。此外，SP-VLA提出动作感知的模型调度与时空语义双感知令牌修剪机制，将VLA与轻量生成器协同执行，在维持准确率的同时实现1.5至2.4倍的加速[38]。BLURR则通过指令前缀KV缓存、混合精度等即插即用的优化，降低有效计算量与端到端延迟[40]。这些工作表明，在不牺牲任务成功率的前提下，VLA有显著的效率提升空间，但多数加速策略仍聚焦于模型内部的冗余消除，尚未深入考虑环境动态与长期规划带来的计算挑战。

2.3 长程任务与感知深化：推理、记忆与世界模型

标准的VLA策略在长时间跨度任务中易受复合误差影响，而对三维空间、动态过程和跨模态线索的感知不足则进一步限制了其泛化能力[1,7,12,13]。针对长程推理，Anticipation-VLA引入自适应子目标生成模型，递归地预测未来子目标以引导策略执行[7]；ACoT-VLA提出以粗糙动作意图序列作为推理链，将显式与隐式动作推理器结合，直接在动作空间中进行思考[15]；MAP-VLA则构建示范记忆库，通过可学习软提示动态增强动作生成，使长程任务在真实机器人上提升25%的成功率[20]。在感知层面，GraphCoT-VLA构建实时更新的3D位姿-物体图，结合结构化思维链，有效应对歧义指令[12]；GeoAware-VLA利用冻结的几何视觉模型提供强几何先验，将未见视角的泛化成功率平均提升35个百分点[36]；Audio-VLA将接触音频纳入感知通道，克服纯视觉模型在交互动态感知上的局限[13]。这些改进虽然显著提升了VLA在特定维度的能力，但其

本质仍是对感知-行动映射的局部修补，缺乏对世界状态演变的系统性建模。

2.4 世界动作模型（WAM）的兴起与核心价值

世界动作模型（WAM）作为VLA的重要替代或演进范式，显式地联合建模未来视觉观察的演变与动作生成，从而将“预测世界如何变化”内化为策略的一部分[5,8]。Fast-WAM通过受控实验剥离了训练期视频预测与测试期未来想象的作用，发现视频协同训练对性能的贡献远大于显式生成未来帧，其变体在取消测试时迭代去噪后，以190ms延迟和超过4倍的推理加速仍保持竞争性能，这暗示世界模型的价值可能主要在于提炼训练期状态表征[5]。OA-WAM则进一步将预测粒度细化到对象层面，将画面分解为机器人槽和多个物体槽，每个槽包含持久的地址向量与时变的内容向量，从而在物体可寻址的空间中推理动作，在LIBERO-Plus几何轴测试上达到最优并展现出强大的对象绑定鲁棒性[8]。HiF-VLA虽未自称WAM，但通过运动表征整合回看、洞察与预见，实现了“边想边做”的时序推理，可视为一种运动中心的世界模型[35]。上述工作共同揭示了一条从VLA向WAM演进的清晰线索：放弃单纯的端到端刺激-反应式映射，转向以世界动态理解为核心的架构设计。然而，现有WAM主要在仿真基准和短期任务上验证，其在大规模真实环境下的长期部署和跨任务泛化能力仍缺乏系统性评估。




图1 Figure 1. Publication trend of the screened literature by year.

3 从 VLA 到 WAM 的范式演进

3.1 范式分野：端到端映射与世界模型预测

VLA 模型的核心范式建立在一个简洁的假设之上：将多模态感知输入直接映射为机器人动作输出。早期研究将这种范式定义为“统一感知、自然语言理解与具身行动于单一计算框架”[10]，其本质是通过大规模预训练的视觉-语言模型（VLM）将高维视觉特征与语言指令对齐，再经由策略头解码为连续或离散的执行指令[11]。这种端到端的设计带来了显著的泛化能力——VLA 模型能够在未见任务上展现出零样本或小样本推理潜力，从而迅速成为机器人操控领域的主导架构[18]。

然而，VLA 范式的内在局限同样清晰。多数 VLA 模型将动作预测视为从感知到行动的直接映射函数，忽视了世界的丰富动力学以及动作与状态演变之间的因果关联[1]。这一批评并非孤立：现有 VLA 模型往往依赖当前观测的马尔可夫假设，缺乏对长时序依赖的有效建模[35]，导致其在需要持续推理和动态适应的长程任务中出现累积误差[7]。换言之，VLA 范式抓住了“看到-理解-执行”的即时性优势，却牺牲了“内部模拟-预判后果-稳健规划”的深层认知能力。

WAM 范式的提出正是为了填补这一空白。与 VLA 的纯反应式映射不同，WAM 显式地建模环境在动作影响下的演化——通常表现为对未来视觉观测或状态的预测[5]。3D-VLA 的早期探索已经暗示了这一转向：通过引入生成式世界模型，使智能体能够在 3D 空间中预测目标图像和点云，从而将规划建立在对未来的“想象”之上[1]。此后，WAM 架构进一步发展出对象级可寻址的世界表征[8]、动作-世界联合预测机制，以及训练期间嵌入视频建模而非测试时显式生成的变体[5]，表明世界模型的真正价值可能在于训练期间优化表征质量，而非推断时的逐帧生成。

3.2 VLA 的内在演进：感知增强与推理深化

即便在 WAM 尚未普及的阶段，VLA 自身也经历了显著的内部演进，逐步向世界模型化的方向靠拢。感知维度上，VLA 模型不再满足于静态 2D 输入：GeoAware-VLA 通过引入冻结的几何先验模型增强对 3D 空间的隐式理解，在未见相机视角下实现成功率平均提升 35 个百分点[36]；GraphCoT-VLA 进一步构建实时可更新的 3D 位姿-物体图，显式建模机械臂关节与目标物体的空间拓扑关系[12]。这些尝试表明，即使维持 VLA 的外部接口不变，内部表征的几何化升级已成为应对复杂操控的必由之路。

推理能力方面的突破同样值得关注。传统 VLA 模型将视觉输入视为静态上下文，缺乏主动回顾环境以消解歧义的能力[29]。Chain-of-Thought 思想的引入改变了这一格局：CoT-VLA 通过自回归预测未来图像帧作为视觉目标，再生成短期动作序列[19]；ACoT-VLA 更进一步，将中间推理步骤直接构建为粗粒度动作意图序列，实现了在动作空间内的“逐步思考”[15]。Anticipation-VLA 则提出适应性、递归式的子目标生成机制，使高层规划能够根据执行状态动态调整[7]。这些演进虽然仍停留在

VLA 框架内，但已显著模糊了与 WAM 的边界——它们本质上都在赋予模型一种对未来的“想象”与“预估”能力。

3.3 效率约束下的范式选择

VLA 范式面临的另一个驱动力来自部署端对实时性、功耗和计算资源的严苛要求。密集大语言模型在边缘设备上的推理延迟可能高达数百毫秒，难以满足高频控制需求[4]。为此，研究者从模型压缩、动态稀疏化、推理加速等多路径寻求突破：

MoLe-VLA 借鉴神经科学的浅脑假说，将 LLM 层视作可动态激活的“层专家”，在提升成功率 9.7% 的同时实现 36.8% 的推理加速[4]；SP-VLA 则联合模型调度与令牌剪枝，将动作分为深思型与直觉型，在 LIBERO 和 SimplerEnv 上分别实现 1.5 倍和 2.4 倍的无损加速[38]。

WAM 在效率维度上提出了一个根本性问题：测试时的未来想象是否必要？Fast-WAM 的消融实验给出了否定回答——保留训练阶段视频建模而省略推断时的显式生成，不仅保持了与“想象-执行”变体相当的性能，还将延迟压缩至 190 毫秒，相比原有 WAM 架构提速 4 倍以上[5]。这一发现具有深远的范式意义：它暗示世界模型的核心优势在于训练期间赋予模型的时序表征能力，而非测试时对未来的逐帧渲染。因此，WAM 不必以牺牲实时性为代价来换取对动态的建模，这也为该范式在实时控制场景中的推广扫除了一个关键障碍。

3.4 研究缺口与未来路径

尽管 WAM 在表征维度和效率权衡上展现出相对于 VLA 的优势，当前研究仍存在若干明显缺口。其一，多数 WAM 评估集中于 LIBERO 等桌面操控基准，其在无人机导航[16]、人形机器人双手操作[26]等更高维度的动力学场景中的有效性和泛化性尚未得到系统验证。其二，WAM 的对象可寻址性虽然提升了扰动场景下的鲁棒性[8]，但其基于槽机制的分解方式在面对大规模、变数量物体时是否仍然可扩展，目前缺乏充分证据。其三，VLA 与 WAM 在方法论层面正在趋同——如 HiF-VLA 所展示的“后见-先见”时序运动建模[35]，或 Dream-VLA 基于扩散语言模型的原生双向生成能力[21]——如何在这两种范式间建立统一的评价标准和理论框架，将是下一阶段需要直面且具有潜在理论贡献的课题。

4 世界-动作模型（WAM）的概念框架

4.1 从端到端映射到生成式世界模型：WAM 的概念跃迁

视觉-语言-动作（VLA）模型核心理念在于建立从感知到动作的直接映射，将视觉观察与语言指令转化为机器人的控制指令 [10, 11]。尽管这一范式在各类具身任务中取得了显著成功，但其本质仍是对专家演示的行为克隆，缺乏对世界动态变化的显式建模 [1, 5]。这种“映射”而非“理解”的局限性，在长程任务与需精细操作的环境中尤为突出——模型难以预测动作的远期后果，也无法在环境状态发生分布外偏移时进行稳健的规划与纠错 [15, 35]。

正是为了突破上述认知瓶颈，世界-动作模型（World Action Model, WAM）作为一种新兴的具身智能框架应运而生。与 VLA 的单向映射不同，WAM 引入了对未来状态的显式生成能力，其核心在于联合预测“世界的演变”与“动作的执行” [5, 8]。具体而言，3D-VLA 模型率先尝试将生成式世界模型注入 VLA 架构，通过训练具身扩散模型预测未来的目标图像与点云，使智能体得以在想象中推演不同动作序列可能引发的场景变化 [1]。这种架构转变的意义在于，模型不再仅仅对当前观测做出反应，而是能够前瞻性地在“潜在未来空间”中进行搜索与评估，从而生成更具远见与物理一致性的动作序列。

4.2 想象-执行范式的反思与 Fast-WAM 的实证分歧

早期的 WAM 普遍遵循“想象-执行”（imagine-then-execute）范式，即在执行动作前，通过迭代视频去噪生成显式的未来视觉状态 [5]。这一方法逻辑上贴近人类通过心理预演进行规划的认知习惯，但高昂的测试时延成为其从仿真走向真实世界应用的主要障碍。Fast-WAM 模型的提出，对此范式提出了根本性挑战。其核心发现是，移除测试时的未来视频预测，仅保留训练阶段的视频共训，模型的动作执行性能依然保持竞争力，且推理速度提升了四倍以上 [5]。这一实证结果表明，WAM 中视频预测的主要价值，或许并非在于推理时产出可供显式检查的未来图像，而在于通过训练过程中的视频建模任务，迫使视觉编码器学习到更丰富的、包含时间动态与因果逻辑的世界表征。这促使我们将 WAM 的概念焦点从“生成未来”转向“理解动态”——即，WAM 的优势源于其拥有一个经过世界动态预训练的强大内部表征，而非其输出的未来画面本身。

4.3 面向对象的可寻址表征：OA-WAM 的架构深化

对 WAM 内部表征形式的探索，进一步推动了该概念框架的精确化。传统方法倾向于将预测的世界状态编码为全局的潜变量或整体图像，这种单一表示在处理指向特定物体的操作指令时显得笨拙，尤其是在物体身份与场景上下文高度纠缠的情况下 [8]。OA-WAM 模型通过解构场景表征回应了这一难题，它将每帧画面分解为一个机器人槽态与多个独立的物体槽态。每个槽态包含持久的地址向量与随时间变化的内容向

量，这种“可寻址”机制允许动作解码器直接定位并操作指令所指的特定物体，而忽略无关或干扰的上下文信息 [8]。这一设计将 WAM 从整体性世界预测推向了结构化理解与交互，通过分离“操作对象”与“对象现状”，显著提升了模型在面对场景扰动时的鲁棒性，为构建更精细、更可靠的 WAM 奠定了基础。

4.4 感知模态的拓展与未来方向

WAM 概念的完备性还要求其具备整合多模态物理信息的能力。当前的 VLA 与 WAM 模型仍高度依赖视觉感知，然而，接触式操作中的力觉、触觉以及声音信号，承载了视觉所无法捕捉的丰富物理交互信息。例如，Audio-VLA 通过引入接触音频感知动态过程，MoDE-VLA 则集成了异构的力与触觉模态，以增强接触丰富型操作的精细度 [13, 26]。将这些多维物理信号统一纳入 WAM 的生成式世界模型框架，使其不仅能“看见”未来，还能“感受”未来交互的力度、质感与声音反馈，将是推动具身智能走向真正物理世界的关键一步。此外，当前对 WAM 的探索仍处于初始阶段，如何构建更加可扩展、计算高效的视频生成骨干，以及如何将任务规划、运动推理与世界模型预测深度融合，均是亟待解决的核心问题 [5, 35]。

5 关键技术与实现路径

5.1 世界模型与生成式架构的融合

5.1.1 从VLA到WAM的范式演进

传统VLA模型将感知到动作的映射学习为直接映射，忽略了世界动态以及动作与动态之间的关系[1]。世界动作模型（WAM）试图弥补这一缺陷，通过显式建模视觉观测在动作作用下的演变来增强策略[5]。然而，大多数现有WAM遵循"想象-执行"范式，在测试时产生显著的迭代视频去噪延迟。Fast-WAM的研究揭示了该领域的一个关键发现：WAM中视频预测的主要价值可能在于训练阶段改善世界表征，而非测试时生成未来观测[5]。这使Fast-WAM在保持与先进方法竞争力的同时，将推理延迟降低至190毫秒，较传统"想象-执行"WAM加速超过4倍[5]。

5.1.2 3D生成世界模型

3D-VLA将生成能力注入VLA模型，通过训练一系列具身扩散模型并将其对齐到基于3D的大语言模型中，用于预测目标图像和点云[1]。该模型引入了与具身环境交互的交互令牌，实现了3D感知、推理和动作的无缝连接[1]。OA-WAM进一步推进了这一方向，将每帧分解为N+1个槽状态，包括一个机器人槽和N个物体槽，每个槽包含持久地址向量和时变内容向量[8]。这种可寻址的物体状态为场景扰动下的鲁棒世界-动作建模提供了有效接口，在LIBERO上达到97.8%的成功率[8]。

5.2 高效模型设计与部署加速

5.2.1 动态计算与模型稀疏化

大规模VLA模型面临部署挑战，主要源于密集大语言模型的高计算需求[4]。MoLe-VLA将每个LLM层概念化为专家，通过时空感知路由器（STAR）根据机器人当前状态选择性激活部分层，模仿大脑中专门用于认知和因果推理的不同信号通路[4]。该架构在十个仿真任务中平均成功率提升9.7%，同时推理加速36.8%[4]。VLA-Adapter则从另一个角度降低部署门槛，仅使用0.5B参数骨干网络，无需任何机器人数据预训练，即可在单个消费级GPU上训练强大的VLA模型[9][32]。

5.2.2 推理系统协同优化

VLA-Perf的分析显示，VLA推理性能受模型缩放、架构选择、长上下文视频输入和异步推理等多因素影响[30]。SP-VLA通过联合模型调度和令牌剪枝实现加速，将VLA动作分为深思熟虑型和直觉型，分别分配给VLA模型和轻量级生成器，在LIBERO上无损加速1.5倍，SimplerEnv上加速2.4倍[38]。BLURR则通过指令前缀键值缓存、混合精度执行和单步展开调度，在不改变模型检查点的情况下加速控制[40]。

5.3 推理增强与长程规划

5.3.1 显式思维链与层级推理

VLA模型在处理长程任务时因误差累积而受限[7]。CoT-VLA引入显式视觉思维链推

理，在生成短动作序列前自回归预测未来图像帧作为视觉子目标，在实际操作任务中性能超越此前最先进模型17%[19]。Anticipation-VLA通过自适应递归生成未来子目标，克服固定粒度任务分解的局限性，使规划路径随任务执行动态调整[7]。ACoT-VLA将推理过程本身制定为粗粒度动作意图的结构化序列，通过显式动作推理器（EAR）和隐式动作推理器（IAR）共同形成条件化下游动作头的动作思维链[15]。

5.3.2 记忆增强与多模态融合

针对VLA模型仅依赖即时传感输入的问题，MAP-VLA从历史演示构建记忆库，通过轨迹相似度匹配检索相关记忆，动态集成到冻结VLA模型中，在长程任务真实机器人评估中性能绝对提升25%[20]。HiF-VLA将运动视为更紧凑的时序上下文表征，通过后见先验编码过去动态，通过预见推理预期未来运动，在LIBERO-Long和CALVIN ABC-D基准上超越强基线[35]。

5.4 多模态感知与几何先验

5.4.1 跨模态感知扩展

视觉依赖限制了VLA在交互和动态过程感知中的能力[13]。Audio-VLA利用接触音频感知接触事件和动态过程反馈，采用预训练DINOv2、SigLIP作为视觉编码器，AudioCLIP作为音频编码器，在LIBERO和RLBench上展现出超越纯视觉方法的性能[13]。E-VLA则针对极端低光和运动模糊场景，直接利用事件流中的运动和结构线索维持感知-动作一致性，在20勒克斯的拾取任务上将成功率从0%提升至90%[27]。

5.4.2 几何感知与空间推理

GeoAware-VLA通过集成冻结预训练几何视觉模型作为特征提取器，将强几何先验注入视觉骨干，在未见相机视角的零样本泛化上平均提升35个百分点[36]。GraphCoT-VLA构建实时可更新的3D姿态-物体图，捕获机器人关节的空间配置和物体间的拓扑关系，通过结构化思维链推理模块整合高层任务理解与未来物体位置的底层想象推理[12]。

6 VLA 与 WAM 的对比分析

6.1 范式分野：端到端映射与生成式世界模型

VLA 模型的核心范式在于将多模态感知输入直接映射为动作序列，其训练目标通常是模仿专家轨迹，缺乏对物理世界动态演化的显式建模 [2][11]。这种端到端策略在结构化环境中表现优异，但面对长序列任务时，易因时空因果关系缺失而积累误差。与此相对，WAM 范式通过引入生成式组分，在动作条件下预测未来的视觉观察或世界状态，从而为动作执行提供前瞻性约束 [5][8]。不过，近期 VLA 研究已开始主动吸纳世界模型理念：3D-VLA 将具身扩散模型对齐至大语言模型，赋予其生成目标图像与点云的能力 [1]；HiF-VLA 更进一步，利用运动表征构建双向时序推理，使 VLA 具备利用“事后”先验与“事前”预览进行动作生成的机制 [35]。这些进展表明，两类模型并非截然对立，而是在表征学习与决策机制上正发生深度互渗。

6.2 推理效率与未来想象的必要性考辨

WAM 典型范式遵循“想象-执行”流程，测试时需通过迭代视频去噪生成未来帧，由此引入显著计算延迟。Fast-WAM 的消融实验对此提出根本性质疑：移除测试时未来预测的变体仍保持竞争力，但完全抛弃训练阶段的视频协同建模则导致性能崩溃（LIBERO 与 RoboTwin 基准），揭示世界模型的主要价值在于训练时塑造更具因果性的表征，而非生成显式的未来观测量 [5]。这一发现挑战了显式未来想象的必要性假设。反观 VLA，显式中间推理同样被用于提升性能，例如 CoT-VLA 以自回归预测未来帧作为视觉思维链，在真实场景操纵任务中优于无推理基线 [19]。然而，此类视觉思维链与 WAM 测试时生成目标本质上承担类似的表征约束功能，其性能增益是否必须经由像素级生成实现，仍有待更严格的控制实验来验证。从计算成本的角度，两类模型均面临实时部署压力。动态层跳过的 MoLe-VLA 将推理加速 36.8% 且成功率提升 9.7% [4]，而 SP-VLA 通过联合模型调度与令牌剪枝在 LIBERO 上实现 1.5 倍无损加速 [38]。这些效率优化方案对 VLA 与 WAM 均具可迁移性。

6.3 表征粒度与鲁棒性：槽位寻址与隐式解码

表征层面的一个关键差异在于对对象实例的可寻址性。OA-WAM 将每一帧分解为“机器人槽+ N 个物体槽”，每个槽包含持久地址向量与时变内容向量，迫使模型在地址层面解耦“操作哪个对象”与“对象当前状态” [8]。因果槽干预实验显示，OA-WAM 的交换绑定余弦相似度达 0.87，而全局表征基线仅为 0.09，在 LIBERO-Plus 几何扰动轴上达到最优性能。相比之下，多数 VLA 仍采用全图编码、隐式动作解码的架构，即便引入 3D 感知（如 GraphCoT-VLA 的实时可更新 3D 姿态-物体图 [12]）或预训练几何视觉特征（GeoAware-VLA [36]），其内部表征的可解释性与对象级别的不变性仍不及显式对象寻址的 WAM。这一差距在指令模糊、场景遮挡或相机视角变化时更为突出，提示未来 VLA 向精细对象寻址方向演进的必要性。

6.4 融合趋势：迈向世界模型先验的策略学习

当前研究前沿正在消解 VLA 与 WAM 之间的清晰边界。Anticipation-VLA 提出自适应、递归的未来子目标生成，高层使用统一多模态模型预测子目标，低层由目标条件 VLA 策略执行动作，实质上构建了一个层次化的世界模型[策略耦合系统，有效缓解长周期任务的复合误差 [7]。Dream-VLA 则基于扩散语言模型骨干，利用其本质上的双向性直接支持动作分块与并行生成，同时获得视频建模的表征收益，在 LIBERO 上达到 97.2% 的平均成功率，超过 π^0 和 GROOT-1 等主流方法 [21]。这些工作暗示，未来的具身基础模型很可能不再需要强制区分 VLA 与 WAM 标签，而应围绕“世界-动作联合建模”这一核心目标，在训练阶段充分吸收环境动态先验，推理阶段则可按需选择是否显式生成未来状态，从而在效率、鲁棒性与任务成功率之间取得动态平衡。

7 具身智能的未来影响

7.1 VLA向3D世界模型的演化

当前VLA模型的核心局限在于其感知维度与推理深度的不足。多数VLA依赖2D视觉输入，缺乏对3D物理世界的整合，同时将动作预测简化为从感知到动作的直接映射，忽略了世界动态与动作之间的因果关联[1]。这一范式缺陷在复杂操作中尤为突出：模型虽能模仿专家轨迹，却无法进行预测性的运动推理[31]。为突破此瓶颈，3D-VLA等新一代模型将3D感知、推理与生成式世界模型无缝链接，通过引入交互令牌与具身扩散模型，赋予模型预测目标图像与点云的能力，从而显著提升了推理、多模态生成与规划水平[1]。这一趋势表明，具身智能正从平面感知向立体认知跃迁，其逻辑不仅在于空间维度的增加，更在于让智能体具备“想象未来场景”以规划动作的能力。GeoAware-VLA的发现佐证了这一方向：通过注入强几何先验，模型能在不依赖显式3D数据的情况下，大幅提升对未见相机视角的泛化能力，平均成功率提升达35个百分点[36]。这表明，稳健的几何基础是构建泛化性智能体的关键构件。

7.2 从VLA到WAM：推理与预测的范式转移

VLA模型的另一关键演进方向是向世界行动模型（WAM）的范式转移。传统VLA直接输出动作，而WAM显式建模视觉观测在动作下的演化，内嵌了前向预测能力[5]。然而，WAM的“想象-执行”范式在测试时需迭代视频去噪，导致显著的推理延迟。Fast-WAM的研究对此提出了根本性质疑：测试时的显式未来想象是否真的必要？其实实验表明，在训练阶段保留视频协同训练但测试时跳过未来预测，模型依然保持竞争力，而去除视频协同训练则导致性能大幅下降[5]。这意味着视频预测的主要价值在于训练阶段改善世界表征，而非测试时生成未来观测。与此同时，OA-WAM引入对象可寻址的槽状态分解，通过对场景中物体与机器人的单独建模，在LIBERO基准上达到97.8%的成功率[8]。这揭示了一条关键路径：从“预测未来画面”转向“构建结构化、可寻址的世界状态”，使行动解码能够精确锁定指令所指对象，尤其在场景扰动下保持稳定。

7.3 长时域推理与多模态感知的突破

具身智能迈向真实世界的另一个关键挑战在于长时域任务的可靠执行。现有VLA模型因缺乏记忆机制与时间推理能力，在长序列任务中面临复合误差的困扰[7][20]。为解决此问题，Anticipation-VLA引入自适应递归的子目标生成机制，使高层规划能够根据环境动态连续调整未来子目标[7]。ACoT-VLA则更进一步，将推理过程直接置于行动空间中，以粗粒度动作意图序列作为显式推理步骤，引导最终策略学习[15]。这些进展共同指向一种层次化推理架构：高层负责自适应规划，低层执行目标条件策略。

与此同时，感知模态的单一性正被不断打破。纯视觉VLA模型在接触式交互与动态过程感知上存在根本局限，Audio-VLA通过引入接触音频感知接触事件与动态反馈，有效克服了这一限制[13]。在极端光照与运动模糊场景下，E-VLA则利用事件相机的运动

与结构线索，在20勒克斯光照下将抓取成功率从0%提升至90%，为具身智能超越传统帧基视觉铺平了道路[27]。

尽管上述进展显著，当前研究仍多集中于仿真环境或受控场景。从VLA到WAM的演进虽降低了延迟，但在完全无结构、动态开放的真实世界中的鲁棒性验证仍相当有限。此外，多模态感知的融合方式、层次化推理的协调机制，以及模型在安全攸关场景下的行为边界，仍是未充分解决的开放问题。未来研究需在系统层面整合高效推理架构、多模态感知与自适应规划，方能使具身智能体真正走出实验室，融入复杂的人类环境。

8 局限性与开放问题

8.1 计算效率与实时部署瓶颈

尽管VLA模型在视觉理解与动作生成上取得了显著进步，但密集的大语言模型骨干导致端侧推理延迟居高不下，严重制约了其在真实机器人控制中的部署。[30] 的分析模型揭示了架构设计与硬件部署共同构成的复杂性能图景，指出现有系统难以兼顾精度与实时性。虽然MoLe-VLA [4]与SP-VLA [38]分别从动态层跳过与“模型调度+令牌剪枝”角度将推理提速了30%以上，BLURR [40]亦通过无训练的缓存与混合精度优化降低了有效计算量，但这些策略多属事后加速，仍缺乏从模型设计阶段就嵌入的实时推理范式。从VLA向世界动作模型（WAM）过渡的动机之一正是对推理效率的期许，因为Fast-WAM [5]证实，跳过测试时未来想象可带来4倍以上的延迟缩减而不损性能。然而，这一发现同时抛出一个根本性开放问题：WAM是否必然需要显式未来生成？训练阶段的视频建模收益与推理阶段的想象成本之间的权衡，尚未得到充分的理论阐释与系统性消融。

8.2 三维环境理解与空间推理局限

多数VLA模型以2D视觉为输入，缺乏对三维物理空间的结构化表征，导致在新视角和场景扰动下泛化能力不足。[1] 由此提出3D-VLA，引入3D基座模型与交互令牌，以增强空间推理能力。GeoAware-VLA [36]则通过冻结的预训练几何视觉编码器注入强几何先验，在未见相机位姿下将成功率提升了35个百分点。但上述方法仍依赖单一静态场景的点云或空间图，未能动态更新环境变化。GraphCoT-VLA [12]虽构建了实时更新的3D位姿-物体图，却未验证其在大规模复杂环境中的可扩展性。将动态3D世界模型无缝融入VLA与WAM框架，且不引入过高的计算开销，是一个尚待解决的问题。

8.3 长程任务与时间推理鸿沟

现有VLA策略普遍隐含马尔可夫性，仅以当前观测驱动动作，缺乏对历史交互的因果追溯和未来状态的预期推理，从而在长程任务中遭受累积错误。[35] 由此提出HiF-VLA，利用运动表征进行双向时间推理，而Anticipation-VLA [7]与CoT-VLA [19]分别通过递归子目标生成与视觉链式思维来弥合这一鸿沟。MAP-VLA [20]亦引入示范记忆库与检索增强，在长程任务中取得25%的绝对提升。然而，这些方法主要处理短期到中期的时间依赖，对于需要全局任务规划与物理常识推理的复杂长程序列，目前的VLA与WAM依然缺乏可靠的内部世界动态模型。长程因果性的学习与抽象目标的层级分解仍然是开放性难题。

8.4 感知鲁棒性与模态完整性

VLA的视觉感知在低光照、运动模糊等退化条件下极易失效。[27] 发现，在20勒克斯光照下，纯视觉VLA执行拾取-放置任务的成功率降至0%，而事件相机的引入可使其回升至90%，表明当前模型对传感阶退化高度敏感。此外，单一视觉模态无法捕捉接

触动态与力觉反馈，这对手部灵巧操作等接触密集型任务至为关键。[26] 提出的 MoDE-VLA 通过残差注入方式整合力与触觉模态，证明了多模态融合的性能增益。然而，如何以计算高效、架构兼容的方式将触觉、音频、事件等多种传感流统一于 VLA 或 WAM，仍是欠缺系统性研究的开放问题。

8.5 世界模型的核心收益与悬置假设

WAM 的核心优势在于通过显式建模视觉状态随动作的演化来提高策略精度。[5] 的受控实验却发现，移除测试时的未来视频生成对动作性能影响甚微，而取消训练期间的视频联合训练则导致性能大幅下降。这一结果挑战了“想象即执行”范式的核心前提，暗示 WAM 的主要收益可能在于利用视频预测来学习更鲁棒的内部表征，而非对未来状态的在线推演。然而，该结论目前仅基于少数基准，是否适用于需要长期规划或动态场景推理的任务尚未证实。与此同时，OA-WAM [8] 提出的对象可寻址世界模型通过分离对象身份与状态的槽式编码，在场景扰动下展现了鲁棒性，但其可扩展性和与高效推理范式的兼容性有待进一步检验。WAM 的架构设计准则——何种世界状态表征、何种未来预测粒度以及何种训练-推理解耦策略——构成了推动具身智能下一步发展的关键研究议程。

9 结论

9.1 VLA 模型的现有成就与核心瓶颈

视觉-语言-动作（VLA）模型通过将预训练的大规模视觉-语言模型与机器人动作生成对齐，已经在多种操作与导航任务中取得了显著性能提升[2][6][11]。研究者通过引入链式思维推理[15][19]、三维感知增强[1][12]与记忆机制[20]，不断推高 VLA 在仿真和真实场景中的成功率。然而，VLA 模型仍面临若干结构性局限：多数模型依赖当前观测的单步映射，缺乏对环境动态与动作长期后果的显式建模[1][35]；在长时程任务中，累积误差难以通过固定粒度或单步推理有效化解[7][25]；此外，模型的计算密集性制约了实时部署与在边缘设备上的运行[4][30][38]。

9.2 世界行动模型（WAM）的范式升级

世界行动模型（World Action Model, WAM）的兴起标志着 VLA 的一次范式扩展。3D-VLA[1] 率先在 VLA 中嵌入生成式世界模型，通过预测目标图像或点云实现规划。HiF-VLA[35] 提出“事后-洞察-预见”框架，利用运动表征进行双向时序推理。OA-WAM[8] 则将场景分解为可寻址的对象槽状态，在保持高效推理的同时提高了场景扰动下的鲁棒性。尤为值得注意的是，Fast-WAM[5] 通过控制实验表明，在测试时省略显式未来视频去噪步骤，仅保留训练阶段的视频建模，依然能保持有竞争力的性能，且推理延迟降低至 190 ms。这一发现暗示，WAM 的核心收益并非来自测试时的“想象-再执行”循环，而在于训练时代码联合学习所获得的更强世界表征。由此，WAM 展现了一条从“端到端映射”走向“内部世界模型推理”的可行路径，同时为降低部署开销提供了关键实证依据。

9.3 关键挑战与研究路径

尽管 WAM 展现了潜力，其大规模实用化仍面临若干关键挑战。首先，高效世界模型的设计需要在表达力与计算成本之间取得平衡，现有混合专家[17]、动态层跳过[4]与令牌剪枝[38]等加速策略是否能在 WAM 中保持精度的同时进一步压缩延迟仍需验证。其次，当前 WAM 的对象可寻址能力多限于单一操作场景，其跨任务、跨实体的泛化性尚缺乏系统评估[8]。多模态感知的融合仍不充分，触觉、音频等对接触丰富操作至关重要的信号尚未广泛纳入世界状态预测[13][26]。此外，真实世界动态交互数据集与可复现的评估基准依然匮乏[37][33]，限制了模型在非结构化环境中的鲁棒性检验。

9.4 未来方向

未来研究应沿以下方向推进：（i）发展训练时利用视频预测、测试时即时执行的高效世界模型架构，进一步解耦世界建模与显式未来帧生成[5]；（ii）将三维场景理解 and 对象中心化表示系统性地融入 WAM 主干，提升空间推理与可寻址操控能力[1][8][12]；（iii）引入多模态感官流，在硬接触与精细操作场景中构建信息更完备的世界

状态估计[13][26]；（iv）将自适应子目标生成与多轮强化学习相结合，赋予 WAM 在线调整规划粒度的能力[7][25]；（v）构建涵盖多样化扰动与长时程交互的标准化评测体系，推动从仿真到真实场景的可信迁移[30][33]。

总体而言，从 VLA 到 WAM 的演进体现了具身智能由感知-动作映射向基于内部世界模型的因果推理转型。若能在效率、泛化与多模态整合方面取得实质性突破，WAM 有望成为下一代通用具身智能体的核心组件。

10 参考文献

- [1] Haoyu Zhen, Xiaowen Qiu, Peihao Chen, Jincheng Yang, Xin Yan, Yilun Du, Yining Hong, Chuang Gan. 2024. 3D-VLA: A 3D Vision-Language-Action Generative World Model..
- [2] Haoran Li, Yuhui Chen, Wenbo Cui, Weiheng Liu, Kai Liu, Mingcai Zhou, Zhengtao Zhang, Dongbin Zhao. 2025. Survey of Vision-Language-Action Models for Embodied Manipulation..
- [3] Qiyao Zhang, Shuhua Zheng, Jianli Sun, Chengxiang Li, Xianke Wu, Zihan Song, Zhiyong Cui, Yisheng Lv, Yonglin Tian. 2026. UAV-Track VLA: Embodied Aerial Tracking via Vision-Language-Action Models..
- [4] Rongyu Zhang, Menghang Dong, Yuan Zhang, Liang Heng, Xiaowei Chi, Gaole Dai, Li Du, Dan Wang, Yuan Du, Shanghang Zhang. 2026. MoLe-VLA: Dynamic Layer-skipping Vision Language Action Model via Mixture-of-Layers for Efficient Robot Manipulation. Proceedings of the AAAI Conference on Artificial Intelligence, DOI:10.1609/aaai.v40i22.38945.
- [5] Tianyuan Yuan, Zibin Dong, Yicheng Liu, Hang Zhao. 2026. Fast-WAM: Do World Action Models Need Test-time Future Imagination?..
- [6] Zhaoshu Yu, Bo Wang, Pengpeng Zeng, Haonan Zhang, Ji Zhang, Zheng Wang, Lianli Gao, Jingkuan Song, Nicu Sebe, Heng Tao Shen. 2025. A Survey on Efficient Vision-Language-Action Models..
- [7] Zhilong Zhang, Wenyu Luo, Haonan Wang, Yifei Sheng, Yidi Wang, Hanyuan Guo, Haoxiang Ren, Xinghao Du, Yuhan Che, Tongtong Cao, Lei Yuan, Yang Yu. 2026. Anticipation-VLA: Solving Long-Horizon Embodied Tasks via Anticipation-based Subgoal Generation..
- [8] Yushan Liu, Peibo Sun, Shoujie Li, Yifan Xie, Lingfeng Zhang, Xintao Chao, Shiyuan Dong, Fang Chen, Xiao-Ping Zhang, Wenbo Ding. 2026. OA-WAM: Object-Addressable World Action Model for Robust Robot Manipulation..
- [9] Yihao Wang, Pengxiang Ding, Lingxiao Li, Can Cui, Zirui Ge, Xinyang Tong, Wenxuan Song, Han Zhao, Wei Zhao, Pengxu Hou, Siteng Huang, Yifan Tang, Wenhui Wang, Ru Zhang, Jianyi Liu, Donglin Wang. 2026. VLA-Adapter: An Effective Paradigm for Tiny-Scale Vision-Language-Action Model. Proceedings of the AAAI Conference on Artificial Intelligence, DOI:10.1609/aaai.v40i22.38931.
- [10] Ranjan Sapkota, Yang Cao, Konstantinos I. Roumeliotis, Manoj Karkee. 2025. Vision-Language-Action (VLA) Models: Concepts, Progress, Applications and Challenges..
- [11] Yuen Ma, Zixing Song, Yuzheng Zhuang, Jianye Hao, Irwin King. 2024. A Survey on Vision-Language-Action Models for Embodied AI..
- [12] Helong Huang, Min Cen, Kai Tan, Xingyue Quan, Guowei Huang, Hong Zhang. 2026. GraphCoT-VLA: A 3D Spatial-Aware Reasoning Vision-Language-Action Model for Robotic Manipulation with Ambiguous Instructions. Proceedings of the AAAI Conference on Artificial Intelligence, DOI:10.1609/aaai.v40i22.38896.
- [13] Xiangyi Wei, Haotian Zhang, Xinyi Cao, Siyu Xie, Weifeng Ge, Yang Li, Changbo

- Wang. 2025. Audio-VLA: Adding Contact Audio Perception to Vision-Language-Action Model for Robotic Manipulation..
- [14] Maoning Ge, Kento Ohtani, Yingjie Niu, Yuxiao Zhang, Kazuya Takeda. 2025. VLA-MP: A Vision-Language-Action Framework for Multimodal Perception and Physics-Constrained Action Generation in Autonomous Driving. *Sensors*, DOI:10.3390/s25196163.
- [15] Linqing Zhong, Yi Liu, Yifei Wei, Ziyu Xiong, Maoqing Yao, Si Liu, Guanghui Ren. 2026. ACoT-VLA: Action Chain-of-Thought for Vision-Language-Action Models..
- [16] Inkyu Sa, Chanoh Park, Ho Seok Ahn. 2026. Vision-Language-Action (VLA) Models for Unmanned Aerial Robotics and Bimanual Manipulation: A Review. DOI:10.20944/preprints202604.0664.v1.
- [17] Chengxuan Li, Xingwan Wang. 2026. DiTEA: Mixture-of-Experts for Vision-Language-Action Model in Robotic Manipulation. *Proceedings of the AAAI Conference on Artificial Intelligence*, DOI:10.1609/aaai.v40i22.38902.
- [18] Kento Kawaharazuka, Jihoon Oh, Jun Yamada, Ingmar Posner, Yuke Zhu. 2025. Vision-Language-Action Models for Robotics: A Review Towards Real-World Applications..
- [19] Qingqing Zhao, Yao Lu, Moo Jin Kim, Zipeng Fu, Zhuoyang Zhang, Yecheng Wu, Zhaoshuo Li, Qianli Ma, Song Han, Chelsea Finn, Ankur Handa, Ming-Yu Liu, Donglai Xiang, Gordon Wetzstein, Tsung-Yi Lin. 2025. CoT-VLA: Visual Chain-of-Thought Reasoning for Vision-Language-Action Models..
- [20] Runhao Li, Wenkai Guo, Zhenyu Wu, Changyuan Wang, Haoyuan Deng, Zhenyu Weng, Yap-Peng Tan, Ziwei Wang. 2025. MAP-VLA: Memory-Augmented Prompting for Vision-Language-Action Model in Robotic Manipulation..
- [21] Jiacheng Ye, Shansan Gong, Jiahui Gao, Junming Fan, Shuang Wu, Wei Bi, Haoli Bai, Lifeng Shang, Lingpeng Kong. 2025. Dream-VL & Dream-VLA: Open Vision-Language and Vision-Language-Action Models with Diffusion Language Model Backbone..
- [22] Pengxiang Ding, Han Zhao, Wenjie Zhang, Wenxuan Song, Min Zhang, Siteng Huang, Ningxi Yang, Donglin Wang. 2024. QUAR-VLA: Vision-Language-Action Model for Quadruped Robots. *Lecture Notes in Computer Science*, DOI:10.1007/978-3-031-72652-1_21.
- [23] Jaehwan Jeong, Evelyn Zhu, Jinying Lin, Emmanuel Jaimes, Tuan-Anh Vu, Jungseock Joo, Sangpil Kim, M. Khalid Jawed. 2026. Your Vision-Language-Action Model Already Has Attention Heads For Path Deviation Detection..
- [24] Wei Zhao, Pengxiang Ding, Min Zhang, Zhefei Gong, Shuanghao Bai, Han Zhao, Donglin Wang. 2025. VLAS: Vision-Language-Action Model With Speech Instructions For Customized Robot Manipulation..
- [25] Yue Hu, Avery Xi, Qixin Xiao, Seth Isaacson, Henry X. Liu, Ram Vasudevan, Maani Ghaffari. 2026. LongNav-R1: Horizon-Adaptive Multi-Turn RL for Long-Horizon VLA Navigation..
- [26] Tutian Tang, Xingyu Ji, Wanli Xing, Ce Hao, Wenqiang Xu, Lin Shao, Cewu Lu, Qiaojun Yu, Jiangmiao Pang, Kaifeng Zhang. 2026. Towards Human-Like Manipulation

through RL-Augmented Teleoperation and Mixture-of-Dexterous-Experts VLA..

[27] Jiajun Zhai, Hao Shi, Shangwei Guo, Kailun Yang, Kaiwei Wang. 2026. E-VLA: Event-Augmented Vision-Language-Action Model for Dark and Blurred Scenes..

[28] Wei Wu, Fan Lu, Yunnan Wang, Shuai Yang, Shi Liu, Fangjing Wang, Qian Zhu, He Sun, Yong Wang, Shuailei Ma, Yiyu Ren, Kejia Zhang, Hui Yu, Jingmei Zhao, Shuai Zhou, Zhenqi Qiu, Houlong Xiong, Ziyu Wang, Zechen Wang, Ran Cheng, Yong-Lu Li, Yongtao Huang, Xing Zhu, Yujun Shen, Kecheng Zheng. 2026. A Pragmatic VLA Foundation Model..

[29] Chaoyang Wang, Wenrui Bao, Sicheng Gao, Bingxin Xu, Yu Tian, Yogesh S. Rawat, Yunhao Ge, Yuzhang Shang. 2026. VLA-Thinker: Boosting Vision-Language-Action Models through Thinking-with-Image Reasoning..

[30] Wenqi Jiang, Jason Clemons, Karu Sankaralingam, Christos Kozyrakis. 2026. How Fast Can I Run My VLA? Demystifying VLA Inference Performance with VLA-Perf..

[31] Yu Fang, Kanchana Ranasinghe, Le Xue, Honglu Zhou, Juntao Tan, Ran Xu, Shelby Heinecke, Caiming Xiong, Silvio Savarese, Daniel Szafir, Mingyu Ding, Michael S. Ryoo, Juan Carlos Niebles. 2025. Robotic VLA Benefits from Joint Learning with Motion Image Diffusion..

[32] Yihao Wang, Pengxiang Ding, Lingxiao Li, Can Cui, Zirui Ge, Xinyang Tong, Wenxuan Song, Han Zhao, Wei Zhao, Pengxu Hou, Siteng Huang, Yifan Tang, Wenhui Wang, Ru Zhang, Jianyi Liu, Donglin Wang. 2025. VLA-Adapter: An Effective Paradigm for Tiny-Scale Vision-Language-Action Model..

[33] Haohan Chi, Huan-ang Gao, Ziming Liu, Jianing Liu, Chenyu Liu, Jinwei Li, Kaisen Yang, Yangcheng Yu, Zeda Wang, Wenyi Li, Leichen Wang, Xingtao Hu, Hao Sun, Hang Zhao, Hao Zhao. 2025. Impromptu VLA: Open Weights and Open Data for Driving Vision-Language-Action Models..

[34] Shaoqi Dong, Chaoyou Fu, Haihan Gao, Yi-Fan Zhang, Chi Yan, Chu Wu, Xiaoyu Liu, Yunhang Shen, Jing Huo, Deqiang Jiang, Haoyu Cao, Yang Gao, Xing Sun, Ran He, Caifeng Shan. 2025. VITA-VLA: Efficiently Teaching Vision-Language Models to Act via Action Expert Distillation..

[35] Minghui Lin, Pengxiang Ding, Shu Wang, Zifeng Zhuang, Yang Liu, Xinyang Tong, Wenxuan Song, Shangke Lyu, Siteng Huang, Donglin Wang. 2025. HiF-VLA: Hindsight, Insight and Foresight through Motion Representation for Vision-Language-Action Models..

[36] Ali Abouzeid, Malak Mansour, Qinbo Sun, Zezhou Sun, Dezhen Song. 2025. GeoAware-VLA: Implicit Geometry Aware Vision-Language-Action Model..

[37] Haochen Zhang, Nader Zantout, Pujith Kachana, Ji Zhang, Wenshan Wang. 2025. IRef-VLA: A Benchmark for Interactive Referential Grounding with Imperfect Language in 3D Scenes..

[38] Ye Li, Yuan Meng, Zewen Sun, Kangye Ji, Chen Tang, Jiajun Fan, Xinzhu Ma, Shutao Xia, Zhi Wang, Wenwu Zhu. 2025. SP-VLA: A Joint Model Scheduling and Token Pruning Approach for VLA Model Acceleration..

- [39] Koffivi Fidèle Gbagbe, Miguel Altamirano Cabrera, Ali Alabbas, Oussama Alyunes, Artem Lykov, Dzmitry Tsetserukou. 2024. Bi-VLA: Vision-Language-Action Model-Based System for Bimanual Robotic Dexterous Manipulations. 2024 IEEE International Conference on Systems, Man, and Cybernetics (SMC), DOI:10.1109/smc54092.2024.10831380.
- [40] Xiaoyu Ma, Zhengqing Yuan, Zheyuan Zhang, Kaiwen Shi, Lichao Sun, Yanfang Ye. 2025. BLURR: A Boosted Low-Resource Inference for Vision-Language-Action Models..

