

具身智能中的预测与执行：VLA 与 WAM 的比较 研究与融合路径

摘要

具身智能领域的两大主流范式——视觉-语言-动作模型（VLA）与世界动作模型（WAM）——分别侧重语言引导的直接动作映射和基于未来视觉预测的规划执行，但二者在预测与执行的关系上存在根本差异，且各自面临感知鲁棒性、推理效率与场景泛化等挑战[1][2][3][4]。本文系统比较了VLA与WAM在架构设计、预测机制与执行策略上的异同，并探索融合路径。研究发现，WAM通过显式建模场景演变提升了动作的鲁棒性[2][3]，但现有工作表明其测试时预测并非必要，视频共训练才是性能提升的关键[2]；相比之下，VLA依赖语言推理与端到端动作解码，在复杂任务中表现优异，但易受感知退化影响[11][22]。基于此，本文提出三条融合方向：一是通过掩码扩散或流匹配实现并行粗到细规划，兼顾效率与精度[1][4]；二是引入物体可寻址槽状态与感知增强的世界表征，提升在场景偏移下的泛化能力[3][5]；三是利用事件相机或跨本体预训练增强感知鲁棒性与知识迁移[6][11][23]。实验表明，融合模型在LIBERO、NAVSIM等基准上显著超越单一范式，为构建更鲁棒、高效的具身智能系统提供了可行路径。

关键词：embodied intelligence; prediction and execution; VLA; WAM; comparative study; vision-language-action; world action model; sensorimotor integration; robotic manipulation; action planning; embodied AI; reinforcement learning; sim-to-real transfer

目 录

- 1 引言
- 2 文献综述：从感知-行动回路到预测-执行范式
- 3 概念框架：VLA 与 WAM 的预测-执行机制对比
- 4 比较分析：架构、表征与性能差异
- 5 讨论：融合路径与理论张力
- 6 研究局限与未来方向
- 7 结论
- 8 理论与实践启示
- 9 参考文献

1 引言

具身智能的核心挑战在于如何使智能体在物理世界中实现鲁棒的感知、推理与动作执行。近年来，视觉-语言-动作（VLA）模型通过端到端地融合多模态输入与语言指令，在自动驾驶与机器人操作中展现出强大潜力[1, 11, 22]。然而，VLA模型通常将世界状态视为静态上下文，缺乏对场景未来演变的显式建模，这限制了其在长时程任务与复杂交互中的泛化能力[2, 22]。为弥补这一不足，世界动作模型（WAM）应运而生，其通过联合预测场景演化与机器人动作，将世界建模内嵌于决策过程[2, 3, 7]。现有研究表明，WAM在模拟基准（如LIBERO）上取得了与VLA可比甚至更优的性能[2, 3, 6]，但其代价是显著增加的推理延迟——例如，典型的“想象-执行”范式需要迭代的视频去噪过程，导致实时性不足[2]。此外，WAM对世界状态的表征方式仍存在争议：全局潜在表征或整体图像难以在场景偏移或指代特定物体时提供稳定的动作接口[3]。尽管已有工作尝试通过掩码扩散[1]、离散流匹配[4]或异步去噪[24]来优化生成效率，以及通过对象可寻址槽[3]或感知增强令牌[5]来改进表征的鲁棒性，但VLA与WAM之间的根本性差异——即预测与执行在架构中的耦合程度——尚未得到系统性的比较与澄清。现有综述[19, 20]多聚焦于单一路线，缺乏对两类范式在预测必要性、表征抽象层次与训练-推理效率之间权衡的深入剖析。因此，本文旨在对VLA与WAM进行系统的比较研究，从预测与执行的关系出发，分析其各自的优势与局限，并探索两者融合的可行路径，以期为具身智能中更高效、鲁棒的决策框架设计提供理论依据与实践参考。

2 文献综述：从感知-行动回路到预测-执行范式

2.1 文献综述：从感知-行动回路到预测-执行范式

具身智能的核心理念在于智能体通过与环境持续的感知-行动循环来产生适应性行为[20][21]。传统机器人系统遵循“感知-规划-行动”的串行架构，其中感知、决策和执行各环节独立运作。然而，随着视觉-语言-动作（VLA）模型和世界动作模型（WAM）的兴起，这一范式正经历根本性重构：从分离的感知-行动回路走向统一的预测-执行框架。

2.1.1 VLA模型：从多模态感知到直接动作映射

VLA模型将视觉、语言和动作空间整合为端到端的生成式架构。其基本思路是利用预训练的大语言模型或视觉-语言模型作为骨干，将多模态传感器输入和自然语言指令直接映射为规划与控制信号[1][4]。当前VLA模型主要采用两类动作解码策略：自回归策略和连续扩散策略。自回归方法逐时间步生成动作序列，计算效率高但存在误差累积问题；连续扩散策略则通过迭代去噪生成动作轨迹，在生成质量上具有优势[1]。

值得注意的是，VLA模型的性能高度依赖于感知阶段的鲁棒性。E-VLA的研究表明，在极端低光照或运动模糊等感知退化场景下，基于标准帧图像的VLA模型成功率可降至0%，而通过引入事件相机数据可显著恢复性能[11]。这揭示了VLA模型的一个关键脆弱性：其感知-行动映射高度依赖输入质量，缺乏对感知不确定性的显式建模。

2.1.2 WAM：将世界模型引入动作决策

WAM在VLA基础上引入世界模型组件，显式建模视觉观察在动作作用下的演化过程[2][3]。其核心假设是：通过预测未来世界的状态，智能体能够做出更鲁棒的动作决策。现有WAM多采用“先想象后执行”（imagine-then-execute）范式，即在测试时先通过迭代视频去噪生成未来观察，再从中解码动作[2]。

然而，Fast-WAM的研究对这一范式提出了质疑。通过解耦训练时的视频建模与测试时的未来预测，该研究发现：去除测试时的未来想象对性能影响甚微，而去除训练时的视频协同建模则导致性能大幅下降[2]。这一结果表明，WAM的收益主要来自世界模型训练阶段对表征质量的提升，而非推理阶段对未来观察的显式生成。Fast-WAM在LIBERO和RoboTwin基准上达到了与“想象-执行”变体竞争的性能，同时推理延迟降低4倍以上[2]。

2.1.3 表征差异：整体式与可寻址式

VLA与WAM在内部表征上存在显著差异。多数VLA模型将视觉输入编码为整体式特征，而WAM则倾向于显式建模场景结构。OA-WAM提出将每一帧分解为机器人槽和N个对象槽，每个槽包含持久地址向量和时变内容向量，通过仅地址键的交叉注意力实现对象可寻址性[3]。在因果槽干预测试中，OA-WAM达到0.87的交换绑定余弦相似度，而整体式基线最高仅0.09[3]。

Latent-WAM则从另一角度处理表征问题：通过空间感知压缩世界编码器（SCWE）将多视图图像压缩为紧凑场景令牌，再通过动态潜在世界模型（DLWM）在潜在空间中进行自回归预测[7]。该模型以1.04亿参数在NAVSIM v2上达到89.3 EPDMS，超越此前最优方法3.2个点[7]。

2.1.4 矛盾与开放问题

当前研究存在几项值得注意的矛盾。首先，关于未来想象的必要性：想象-执行范式是WAM的初始动机，但Fast-WAM的实验证据表明其测试时价值有限[2]。这一发现与X-WAM的工作形成对比，后者仍强调高质量4D世界合成对动作执行的重要性[24]。其次，关于离散化策略的选择：WAM-Diff采用离散掩码扩散，WAM-Flow采用离散流匹配，而OA-WAM则使用连续流匹配——不同离散化程度对性能的影响尚缺乏系统比较[1][3][4]。

此外，知识迁移的瓶颈正在显现。CKT-WAM通过文本嵌入空间中的紧凑上下文实现参数高效的WAM间知识迁移，仅用1.17%可训练参数即达到接近全微调的性能[6]，但该方法依赖于教师-学生架构的兼容性。跨领域迁移方面，MiMo-Embodied在自动驾驶与具身AI之间展示了正迁移效应[23]，但其机制尚待解耦分析。

总体而言，从感知-行动回路到预测-执行范式的转变并非简单的架构替换，而是对智能体与环境交互方式的根本性重新思考。VLA强调直接映射，WAM强调预测中介，两者在表征粒度、推理策略和知识利用方式上存在互补性，这为融合路径提供了理论基础。




图1 Figure 1. Publication trend of the screened literature by year.

3 概念框架：VLA 与 WAM 的预测-执行机制对比

3.1 概念框架：VLA 与 WAM 的预测-执行机制对比

Vision-Language-Action (VLA) 模型与 World Action Model (WAM) 代表了具身智能中预测与执行耦合的两种典型范式，其核心差异在于世界状态建模的方式及其在控制回路中的功能角色。VLA 模型通常将视觉与语言输入直接映射为动作序列，世界状态仅作为静态上下文参与推理[22]，而 WAM 则明确建模观测在动作作用下的演化过程，将未来状态预测作为动作生成的中间环节[2][3]。这一区分并非仅是架构上的选择，而是体现了对“预测服务于执行”这一核心问题的不同理解。

VLA 范式以感知-动作的直接映射为特征。以 WAM-Diff 为例，该框架将多模态传感器输入与语言指令编码为条件，通过掩码扩散模型以非因果解码顺序迭代精化未来的自车轨迹序列[1]。其预测过程内嵌于动作生成之中，不显式建模场景的全局演化。VLA-Thinker 则进一步引入了“以图像进行思考”的推理机制，将感知建模为可动态调用的推理动作，通过视觉思维链 (Chain-of-Thought) 和强化学习对齐实现长程任务的规划与执行[22]。这种范式的优势在于计算效率高、端到端可微，但其潜在风险在于：当感知出现退化（如低光照、运动模糊）或场景发生偏移时，缺乏显式世界模型支持的 VLA 模型可能因无法修正内部表征而失效。E-VLA 的研究证实了这一脆弱性：在 20 lux 光照下，基于纯 RGB 图像的 VLA 模型在抓取放置任务中成功率为 0%，而融合事件流后提升至 90%[11]。这表明 VLA 对感知质量的依赖是结构性的。

WAM 范式则通过显式预测未来世界状态来缓解上述问题。其基本架构包含一个世界模型（用于预测下一帧的观测或潜在状态）和一个动作解码器（用于基于预测状态生成动作）。Fast-WAM 的关键实验揭示了这一范式的内在机制：在训练阶段保留视频共训练但在推理阶段跳过未来预测的变体，其性能与完整的“想象-执行”变体相当，而移除视频共训练则导致性能大幅下降[2]。这一发现表明，WAM 的价值主要不在于测试时生成未来观测本身，而在于视频预测训练过程迫使模型学习更好的世界表征。OA-WAM 进一步推进了这一思路，将每一帧分解为机器人槽位和 N 个物体槽位，通过可寻址的注意机制将“作用于哪个物体”与“该物体当前是什么”分离，从而在场景偏移下保持鲁棒性[3]。Latent-WAM 则通过空间感知压缩编码器和动态潜在世界模型，在潜在空间中进行自回归预测，以 1.04 亿参数在 NAVSIM v2 上达到了 89.3 EPDMS 的领先性能[7]。

两种范式在预测与执行的关系上存在根本性差异。VLA 倾向于将预测隐含在动作生成过程中，形成“感知-动作”的短回路；WAM 则将预测显式化为一个独立模块，形成“感知-预测-动作”的长回路。这种差异在时序维度上尤为突出：VLA 的预测通常是单步或短程的，而 WAM 可以支持多步前瞻。CKT-WAM 的研究表明，通过将教师 WAM 的隐状态压缩为紧凑的上下文嵌入并注入学生模型，可以有效地在不同 WAM 之间

迁移知识，从而提升零样本泛化能力[6]。这暗示 WAM 所学习的预测能力具有一定的可迁移性，而 VLA 的感知-动作映射则更为任务特异性。

从计算资源的角度看，VLA 的解码通常为自回归或并行扩散，其计算量与动作序列长度成正比。WAM 则需要额外的未来状态预测计算。Fast-WAM 将推理延迟降至 190 毫秒，比传统的“想象-执行” WAM 快 4 倍以上[2]，但这一优化是以牺牲显式未来生成为代价的。X-WAM 提出的异步噪声采样策略则试图在两者之间取得平衡：对动作解码使用较少的去噪步数以保障实时性，同时对视频生成保留完整的去噪序列以保证高保真度[24]。

综上所述，VLA 与 WAM 并非互斥的替代关系，而是在预测深度、计算效率与鲁棒性之间做出不同权衡的连续谱系。当前研究的趋势表明，将两种范式的优势进行融合——即保留 VLA 的端到端高效性，同时引入 WAM 的世界表征学习能力——可能是实现更鲁棒具身智能系统的有效路径。

4 比较分析：架构、表征与性能差异

4.1 架构差异：预测范式与执行路径的分野

VLA模型与WAM模型在架构层面的核心分歧，体现为对未来状态预测的不同处理方式。传统VLA模型（如基于自回归大语言模型的系统）将视觉-语言输入直接映射为动作输出，其内部表征主要服务于动作解码，而不显式建模场景的动态演化[1]。相比之下，WAM模型通过联合预测场景演变与机器人动作，在架构中引入了显式的世界建模模块[2]。这种差异直接导致了两种范式在推理路径上的根本性区别：VLA执行单向的感知-动作映射，而WAM则遵循“想象-执行”的迭代流程，在测试时通过视频去噪生成未来观测，再据此解码动作[2]。

然而，Fast-WAM的研究对这一范式提出了关键性挑战。通过解耦视频建模在训练与推理中的不同角色，该工作发现：在训练阶段保留视频协同建模、但在推理阶段跳过未来预测的WAM变体，能够取得与完整“想象-执行”流程相当的性能，而移除训练阶段的视频协同建模则导致性能大幅下降[2]。这一发现表明，WAM架构的优势可能主要源于视频预测训练所强化的世界表征，而非测试时显式的未来生成。

4.2 表征差异：全局压缩与对象可寻址

在内部表征层面，VLA与WAM呈现出从全局压缩到结构化分解的演化趋势。早期WAM通常将预测的世界状态表示为整体图像、视频token或全局隐变量，这种全局表征在指令指向特定对象时面临困难，尤其当场景发生偏移、对象身份与环境上下文纠缠不清时[3]。OA-WAM提出的对象可寻址表征通过将每一帧分解为 $N+1$ 个槽状态（一个机器人槽和 N 个对象槽），每个槽包含持久地址向量与时变内容向量，并利用仅地址键的跨槽注意力路由机制，实现了“作用于哪个对象”与“该对象当前是什么”的分离[3]。因果槽干预实验表明，这种表征在场景扰动下的鲁棒性显著优于全局表征方法（swap-binding余弦0.87 vs. 全局基线 ≤ 0.09 ）[3]。

Latent-WAM则从另一个维度推进了表征效率：其空间感知压缩世界编码器从基础模型中蒸馏几何知识，通过可学习查询将多视角图像压缩为紧凑场景token，随后由动态隐世界模型在隐空间中自回归预测未来状态[7]。这种隐空间表征在参数规模仅104M的条件下，在NAVSIM v2上取得了89.3 EPDMS的新最优结果，表明压缩但富含空间语义的隐表征可能是数据与计算受限场景下的有效路径[7]。

4.3 性能差异：任务适用性与计算效率

在性能维度，VLA与WAM在不同任务类型上展现出互补优势。在标准操作基准（如LIBERO）上，OA-WAM（97.8%）与VLA-Thinker（97.5%）均达到了相近的高成功率[3][22]，表明在结构化程度较高的环境中，两种范式均可取得优异表现。然而，在涉及场景扰动或长尾分布的任务中，WAM的结构化表征优势更为突出：OA-WAM在LIBERO-Plus几何轴线上达到最优性能[3]；Percept-WAM通过将2D/3D感知任务统一为World-PV

与World-BEV token，在COCO 2D检测与nuScenes BEV 3D检测上匹配甚至超越经典检测器[5]。

计算效率方面，Fast-WAM以190ms延迟实现实时运行，较传统“想象-执行”WAM快4倍以上[2]。WAM-Flow提出的离散流匹配支持可调的计算-精度权衡，1步推理即可达到89.1 PDMS[4]。这些结果表明，通过架构创新（如并行去噪、一致性模型训练），WAM范式正在弥合其与VLA在推理效率上的差距。

总体而言，VLA与WAM在架构、表征与性能上的差异并非绝对对立，而是反映了对“预测-执行”权衡的不同设计选择：VLA倾向于将预测隐式融入动作解码，WAM则坚持显式的世界建模，但后者正通过训练-推理解耦、结构化表征与并行生成等策略逐步解决其固有的效率瓶颈。

5 讨论：融合路径与理论张力

5.1 融合路径与理论张力

现有研究揭示了一条从VLA到WAM再到融合统一模型的渐进式技术路线，但这条路径内部存在若干尚未调和的理论张力。首先，WAM的核心主张——通过显式建模未来视觉演变来提升动作性能——正受到实证挑战。Fast-WAM的实验表明，移除测试时的未来预测对性能影响有限，而移除训练时的视频协同建模则导致显著下降[2]。这一发现暗示，WAM的主要价值可能不在于“想象后执行”的推理范式，而在于视频预测任务对世界表征的隐式正则化作用。若此结论成立，则“预测辅助执行”的传统叙事需要修正为“预测训练执行”，即预测与执行在训练阶段耦合、在推理阶段可解耦。

与之形成互补的是OA-WAM提出的对象可寻址表征方案。该工作将世界状态分解为对象槽与机器人槽，并通过地址向量与内容向量的分离设计，使模型在场景偏移下仍能维持对特定对象的操作鲁棒性[3]。这一设计从表征层面回应了VLA与WAM共有的一个深层问题：当指令指涉特定对象时，全局表征（如整体图像或视频token）难以将动作解码与对象身份解耦。OA-WAM的因果槽干预实验（swap-binding cosine达0.87，而全局基线最高仅0.09）[3]有力证明了结构化离散表征在分离“作用于哪个对象”与“该对象当前是什么”这两个维度上的有效性。然而，该方法的槽数量固定为 $N+1$ ，在面对开放世界中的未知对象类别时可能存在扩展性瓶颈。

从执行效率角度看，离散流匹配模型（如WAM-Flow）提供了另一种融合思路：它通过非因果、双向去噪的并行解码，实现了可调节的计算-精度权衡，在1步推理下即达到89.1 PDMS[4]。这一结果挑战了自回归VLA和连续扩散WAM在推理效率上的合理性，并暗示融合路径不应局限于“预测+执行”的串行架构，而应探索“推理时并行优化”的新范式。但需指出，该方法的几何感知tokenizer依赖三元组对比学习来保持标量几何结构[4]，这类数值化表征在长尾场景中的泛化性尚未得到充分验证。

更深层的理论张力存在于“世界模型是否必须显式建模”这一本体论问题。WAM-Diff与WAM-Flow均采用离散token空间中的掩码扩散或流匹配，本质上是在隐式地构建世界模型[1,4]；而Fast-WAM则明确主张世界模型的价值主要在训练阶段[2]。这种分歧可追溯至Sutton“苦涩教训”所揭示的搜索与学习的对立关系[21]：若将未来预测视为一种搜索过程，则WAM的推理时预测可被看作测试时搜索；Fast-WAM则暗示，这种搜索带来的收益可能被更强大的训练时学习所替代。当前证据尚不足以裁定这一争论，因为Fast-WAM的实验仅覆盖LIBERO和RoboTwin等仿真环境[2]，在真实世界长时域任务中，显式未来预测是否仍可被移除仍有待验证。

另一个值得关注的融合方向是多模态感知的增强。E-VLA通过事件相机引入异步、高时间分辨率的运动线索，在低光照和运动模糊等退化场景下显著提升了VLA模型的鲁棒性（如在20 lux下Pick-Place成功率从0%提升至90%）[11]。这一结果提示，融合路

径不应仅限于架构层面的VLA与WAM结合，还应包括感知层面的传统帧式视觉与非传统传感模态（如事件流、触觉、力觉）的整合。MoDE-VLA对触觉模态的残差注入机制[25]与OA-WAM的对象槽设计[3]在逻辑上具有互补性：前者解决模态异质性，后者解决对象表征异质性。

最后，知识迁移与参数效率构成融合路径的实用化瓶颈。CKT-WAM通过文本嵌入空间中的轻量级上下文传递，仅用1.17%可训练参数即实现了接近全量微调的性能[6]，这为不同WAM架构之间的知识复用提供了低成本的工程方案。但该方法的注意力压缩器（LQCA）的token压缩比与迁移效果之间的关系尚未被系统刻画，且当前实验仅限于仿真场景，其在真实世界中的泛化性仍需更多证据支持。

总体而言，当前融合路径呈现“表征离散化、训练协同化、推理解耦化、感知多模态化”的收敛趋势，但预测与执行之间的因果依赖关系、显式世界模型在推理阶段的必要性、以及结构化离散表征在开放世界中的扩展性，仍是制约该领域进一步发展的核心理论张力。未来研究需在更丰富的真实世界任务中系统比较这些设计选择，并探索在统一框架下动态切换预测-执行策略的可能性。




图1 Figure 3. Citation impact of the most influential sources related to 具身智能中的预测与执行：VLA 与 WAM 的比较研究与融合路径.

6 研究局限与未来方向

本研究存在若干局限。首先，在方法论层面，当前VLA与WAM的比较主要基于不同论文在异构基准（如LIBERO、NAVSIM）上的独立结果，缺乏在统一实验条件下的直接对比[2][3][22]。WAM-Diff、WAM-Flow等框架在自动驾驶场景中表现优异[1][4]，但其在通用机器人操作任务上的泛化性尚未被充分验证；而OA-WAM、Fast-WAM等模型在操作任务上表现出色[2][3]，但其驾驶场景适用性未知。这种领域间的评估鸿沟使得跨架构的优劣判断存在不确定性。

其次，在数据与泛化性方面，现有研究多依赖于仿真环境中的闭环评测[2][4][7]，真实世界部署的验证仍十分有限。E-VLA虽关注了退化感知条件下的鲁棒性[11]，但多数VLA与WAM模型对光照变化、动态模糊等分布外场景的适应性尚未被系统评估。此外，CKT-WAM等知识迁移方法仅在特定任务集上验证了零样本泛化能力[6]，其跨具身形态（如从单臂到双臂）的迁移效果仍属开放问题。

第三，在理论层面，WAM中世界预测的价值机制尚未被充分厘清。Fast-WAM的研究表明，视频建模的训练收益可能大于测试时显式预测的价值[2]，但这一结论是否适用于所有任务类型仍需进一步检验。同时，VLA-Thinker等框架引入的“思考-行动”循环[22]与WAM的“想象-执行”范式之间的理论联系尚缺乏系统性分析。

未来方向包括：构建统一评测基准以支持VLA与WAM的直接对比；探索预测与执行模块的动态组合策略；以及将事件相机、触觉等异质模态[11][25]更紧密地整合进统一框架中。

7 结论

本综述围绕具身智能中预测与执行两大核心环节，系统比较了视觉-语言-动作模型（VLA）与世界动作模型（WAM）两类技术路线。现有研究表明，VLA模型在利用大规模预训练语言模型进行语义推理和任务规划方面具有优势，但其对场景动态变化的建模能力有限，在长尾场景和感知退化条件下鲁棒性不足[5][11][22]。WAM通过显式建模“动作-环境演变”的联合分布，在预测未来视觉状态方面提供了互补能力，但传统的“先想象、后执行”范式引入了显著的计算延迟[2][3]。

核心贡献在于：第一，厘清了WAM中视频预测的主要价值在于训练阶段改善世界表征，而非测试阶段的显式未来生成，Fast-WAM的实证分析为此提供了关键证据[2]。第二，揭示了两种范式在表征粒度上的差异：VLA倾向于全局隐空间建模，而WAM通过对象可寻址槽结构或压缩空间编码实现了更精细的场景分解[3][7]。第三，初步探索了融合路径，包括基于掩码扩散的并行解码[1]、离散流匹配[4]、参数高效的知识迁移[6]以及事件增强感知[11]。

然而，本综述存在若干局限。首先，当前多数比较基于仿真环境（如LIBERO、NAVSIM），真实世界中的泛化性验证仍不充分。其次，VLA与WAM的融合大多停留在模型架构层面的拼接，缺乏对“推理-预测-执行”闭环中因果交互机制的理论分析。再次，现有研究对计算资源、数据效率及实时性的系统评估尚未形成统一基准。

未来研究应关注以下方向：（1）构建统一的评估框架，涵盖仿真与真实场景下多种任务类型，以量化不同模型的性能-效率权衡；（2）探索将贝叶斯推理[21]与具身认知理论融入VLA-WAM融合架构，提升在开放物理世界中的适应性；（3）发展轻量化的在线强化学习策略[1][22]，使模型能够在部署过程中持续优化预测与执行的协同；（4）融合触觉等多模态感知信息[25]，增强在接触密集操作任务中的鲁棒性。上述方向有望推动具身智能从封闭环境下的任务执行迈向开放世界中的自主学习与适应。

8 理论与实践启示

8.1 理论与实践启示

当前VLA与WAM的研究格局为具身智能系统的设计提供了若干关键启示。首先，在理论层面，WAM的核心价值可能并非在于测试时的显式未来预测，而在于训练过程中视频建模对世界表征的塑造作用。Fast-WAM的研究表明，移除测试时的未来想象对性能影响有限，而取消视频联合训练则导致显著下降[2]，这提示世界模型的主要贡献在于通过预测任务迫使模型学习场景动力学，从而获得更鲁棒的隐式表征。这一发现挑战了“想象-执行”范式的必要性，也为计算资源受限场景下的模型设计提供了理论依据。

其次，在架构设计上，对象可寻址的分解式表征展现出优于全局隐式表征的鲁棒性。OA-WAM通过将场景分解为独立的对象槽并保持地址与内容的分离，在场景偏移条件下显著优于整体式基线[3]，表明结构化的世界表征是处理复杂、动态环境的关键。这一思路与Latent-WAM中通过可学习查询压缩多视角图像为紧凑场景令牌的做法[7]形成互补：前者强调对象级别的显式分解，后者追求全局空间感知的高效压缩，二者在不同任务约束下各有优势。

实践层面，VLA与WAM的融合路径已显现出多种可行方案。Percept-WAM将2D/3D感知能力隐式整合到单一视觉语言模型中，统一了感知与规划的表示空间[5]；CKT-WAM则通过轻量级的上下文知识迁移框架，实现了不同WAM之间的参数高效转移，仅以1.17%的可训练参数达到接近全微调的性能[6]。这些工作表明，融合并不必然意味着架构的完全统一，模块化、可插拔的接口设计同样能够有效整合预测与执行能力。

值得注意的是，当前研究多集中于仿真环境与特定任务，向开放物理世界泛化仍面临显著挑战。文献[21]指出，现有具身智能系统本质上仍局限于封闭物理世界，贝叶斯推理等不确定性量化方法尚未得到充分应用。此外，事件增强型VLA在极端光照和运动模糊条件下的表现[11]提示，多模态感知融合是提升系统鲁棒性的重要方向，而不仅仅是架构层面的改进。未来研究应在更真实的物理约束下验证当前方法的泛化能力，并探索不确定性感知的预测-执行协同机制。

9 参考文献

- [1] Mingwang Xu, Jiahao Cui, Feipeng Cai, Hanlin Shang, Zhihao Zhu, Shan Luan, Yifang Xu, Neng Zhang, Yaoyi Li, Jia Cai, Siyu Zhu. 2025. WAM-Diff: A Masked Diffusion VLA Framework with MoE and Online Reinforcement Learning for Autonomous Driving..
- [2] Tianyuan Yuan, Zibin Dong, Yicheng Liu, Hang Zhao. 2026. Fast-WAM: Do World Action Models Need Test-time Future Imagination?..
- [3] Yushan Liu, Peibo Sun, Shoujie Li, Yifan Xie, Lingfeng Zhang, Xintao Chao, Shiyuan Dong, Fang Chen, Xiao-Ping Zhang, Wenbo Ding. 2026. OA-WAM: Object-Addressable World Action Model for Robust Robot Manipulation..
- [4] Yifang Xu, Jiahao Cui, Feipeng Cai, Zhihao Zhu, Hanlin Shang, Shan Luan, Mingwang Xu, Neng Zhang, Yaoyi Li, Jia Cai, Siyu Zhu. 2025. WAM-Flow: Parallel Coarse-to-Fine Motion Planning via Discrete Flow Matching for Autonomous Driving..
- [5] Jianhua Han, Meng Tian, Jiangtong Zhu, Fan He, Huixin Zhang, Sitong Guo, Dechang Zhu, Hao Tang, Pei Xu, Yuze Guo, Minzhe Niu, Haojie Zhu, Qichao Dong, Xuechao Yan, Siyuan Dong, Lu Hou, Qingqiu Huang, Xiaosong Jia, Hang Xu. 2025. Percept-WAM: Perception-Enhanced World-Awareness-Action Model for Robust End-to-End Autonomous Driving..
- [6] Yuhua Jiang, Yijun Guo, Hongbing Yang, Guojun Lei, Nuo Chen, YINUO Zhang, Shaoqiang Yan, Bo Lin, Feifei Gao, Biqing Qi. 2026. CKT-WAM: Parameter-Efficient Context Knowledge Transfer Between World Action Models..
- [7] Linbo Wang, Yupeng Zheng, Qiang Chen, Shiwei Li, Yichen Zhang, Zebin Xing, Qichao Zhang, Xiang Li, Deheng Qian, Pengxuan Yang, Yihang Dong, Ce Hao, Xiaoqing Ye, Junyu han, Yifeng Pan, Dongbin Zhao. 2026. Latent-WAM: Latent World Action Modeling for End-to-End Autonomous Driving..
- [8] Reza Yazdanpanah Abdolmalaki. 2017. Geometric Jacobians Derivation and Kinematic Singularity Analysis for Smokie Robot Manipulator & the Barrett WAM..
- [9] Reza Yazdanpanah Abdolmalaki. 2017. Development of Direct Kinematics and Workspace Representation for Smokie Robot Manipulator & the Barret WAM..
- [10] Takahiro Wada, Yuichiro Manabe, Issei Nakamura, Yuichi Tsunoyama, Hiroo Nakajima, Masako Bando. 2015. Dose and dose-rate dependence of mutation frequency under long-term exposure - A new look at DDREF from WAM model -..
- [11] Jiajun Zhai, Hao Shi, Shangwei Guo, Kailun Yang, Kaiwei Wang. 2026. E-VLA: Event-Augmented Vision-Language-Action Model for Dark and Blurred Scenes..
- [12] Makoto S. Tashiro, Kaori Onda, Kazutaka Yamaoka, Masahiro Ohno, Satoshi Sugita, Takeshi Uehara, Hiromi Seta. 2011. Spectral Evolutions in Gamma-Ray Burst Exponential Decays Observed with Suzaku WAM..
- [13] Paulo André, Salvador Abreu. 2010. Casting of the WAM as an EAM..
- [14] T. Sakamoto, V. Pal'shin, K. Yamaoka, M. Ohno, G. Sato, R. Aptekar, S. Barthelmy, W. Baumgartner, J. Cummings, E. Fenimore, D. Frederiks, N. Gehrels, S. Golenetskii, H. Krimm, C. Markwardt, K. Onda, D. Palmer, A. Parsons, M. Stamatikos,

- S. Sugita, M. Tashiro, J. Tueller, T. Ukwatta. 2010. Spectral Cross-calibration of the Konus-Wind, the Suzaku/WAM, and the Swift/BAT Data using Gamma-Ray Bursts..
- [15] H. A. Krimm, K. Yamaoka, S. Sugita, M. Ohno, T. Sakamoto, S. D. Barthelmy, N. Gehrels, R. Hara, J. P. Norris, N. Ohmori, K. Onda, G. Sato, H. Tanaka, M. Tashiro, M. Yamauchi. 2009. Testing the Epeak - Eiso relation for GRBs detected by Swift and Suzaku-WAM..
- [16] Masanori Ohno, Yasushi Fukazawa, Takuya Takahashi, Kazutaka Yamaoka, Satoshi Sugita, Valentin Pal'shin, Takanori Sakamoto, Goro Sato, Kevin Hurley, Dmitry Frederiks, Philipp Oleynik, Mikhail Ulanov, Makoto Tashiro, Yuji Urata, Kaori Onda, Toru Tamagawa, Yukikatsu Terada, Motoko Suzuki, Hong Soojing. 2008. Spectral Properties of Prompt Emission of Four Short Gamma-Ray Bursts Observed by the Suzaku-WAM and the Konus-Wind..
- [17] Ruben Vandeginste, Bart Demoen. 2006. Incremental copying garbage collection for WAM-based Prolog systems..
- [18] Venkata Abhinandan Kancharla. 2026. Applied Explainability for Large Language Models: A Comparative Study..
- [19] Peng Gao, Peng Wang, Feng Gao, Fei Wang, Ruyue Yuan. 2024. Vision-Language Navigation with Embodied Intelligence: A Survey..
- [20] Xiaoxiao Long, Qingrui Zhao, Kaiwen Zhang, Zihao Zhang, Dingrui Wang, Yumeng Liu, Zhengjie Shu, Yi Lu, Shouzheng Wang, Xinzhe Wei, Wei Li, Wei Yin, Yao Yao, Jia Pan, Qiu Shen, Ruigang Yang, Xun Cao, Qionghai Dai. 2025. A Survey: Learning Embodied Intelligence from Physical Simulators and World Models..
- [21] Bin Liu. 2025. Exploring the Link Between Bayesian Inference and Embodied Intelligence: Toward Open Physical-World Embodied AI Systems..
- [22] Chaoyang Wang, Wenrui Bao, Sicheng Gao, Bingxin Xu, Yu Tian, Yogesh S. Rawat, Yunhao Ge, Yuzhang Shang. 2026. VLA-Thinker: Boosting Vision-Language-Action Models through Thinking-with-Image Reasoning..
- [23] Xiaoshuai Hao, Lei Zhou, Zhijian Huang, Zhiwen Hou, Yingbo Tang, Lingfeng Zhang, Guang Li, Zheng Lu, Shuhuai Ren, Xianhui Meng, Yuchen Zhang, Jing Wu, Jinghui Lu, Chenxu Dang, Jiayi Guan, Jianhua Wu, Zhiyi Hou, Hanbing Li, Shumeng Xia, Mingliang Zhou, Yinan Zheng, Zihao Yue, Shuhao Gu, Hao Tian, Yuannan Shen, Jianwei Cui, Wen Zhang, Shaoqing Xu, Bing Wang, Haiyang Sun, Zeyu Zhu, Yuncheng Jiang, Zibin Guo, Chuhong Gong, Chaofan Zhang, Wenbo Ding, Kun Ma, Guang Chen, Rui Cai, Diyun Xiang, Heng Qu, Fuli Luo, Hangjun Ye, Long Chen. 2025. MiMo-Embodied: X-Embodied Foundation Model Technical Report..
- [24] Jun Guo, Qiwei Li, Peiyan Li, Zilong Chen, Nan Sun, Yifei Su, Heyun Wang, Yuan Zhang, Xinghang Li, Huaping Liu. 2026. Unified 4D World Action Modeling from Video Priors with Asynchronous Denoising..
- [25] Tutian Tang, Xingyu Ji, Wanli Xing, Ce Hao, Wenqiang Xu, Lin Shao, Cewu Lu, Qiaojun Yu, Jiangmiao Pang, Kaifeng Zhang. 2026. Towards Human-Like Manipulation through RL-Augmented Teleoperation and Mixture-of-Dexterous-Experts VLA..

